

**Rozpoznawanie emocji z głosu.  
Porównanie algorytmu k najbliższych sąsiadów  
oraz  
algorytmu używającego ukrytych modeli  
Markowa w problemie rozpoznawanie emocji  
z głosu**

(Speech emotion recognition.  
Comparison of the operation of the k nearest neighbors algorithm and  
an algorithm using hidden Markov models in the problem of recognizing  
emotions from voice)

Elżbieta Plaszczyk

Praca inżynierska

**Promotor:** dr Marek Materzok

Uniwersytet Wrocławski  
Wydział Matematyki i Informatyki  
Instytut Informatyki

7 lutego 2018



## Streszczenie

W ramach projektu został stworzony i opisany program, którego celem jest wydobywanie konkretnych cech z fragmentów wypowiedzi znajdujących się w plikach .wav i na ich podstawie rozpoznawanie czterech emocji: smutek, radość, złość i znużenie. Jako cechy dźwięku, które wydobyto i użyto do rozpoznawania stanu emocjonalnego, wybrano: ton podstawowy i natężenie dźwięku. W celu klasyfikacji i przewidywania emocji program korzysta z jednego z dwóch zaimplementowanych algorytmów: k najbliższych sąsiadów oraz ukryte modele Markowa, których schemat działania został opisany w pracy. Użytkownik ma możliwość uruchomienia programu z każdym z tych algorytmów. Program został przetestowany oraz wyniki poprawności rozpoznawania emocji na każdym z tych algorytmów zostały zaprezentowane w pracy.

---

This document describes a program which was created as part of an engineering project and the result of testing it. The aim of the program is to extract specific features from fragments of statements contained in .wav files and based on these data, recognition of four emotions: sadness, anger, happiness and boredom. The basic tone and sound intensity were selected, as sound features that were extracted and used to recognize the emotional state. In order to classify and predict emotions, the program uses one of the two implemented algorithms: k nearest neighbors and hidden Markov models, the flowchart of which is described in the paper. The user can run the program with each of these algorithms. The program was tested and the results of the correctness of emotion recognition on each of these algorithms were presented in the work.



# Spis treści

<b>1. Wprowadzenie</b>	<b>7</b>
1.1. Geneza projektu . . . . .	7
1.2. Cel projektu . . . . .	8
1.3. Zakres pracy . . . . .	8
<b>2. Stan wiedzy w zakresie tematyki pracy</b>	<b>10</b>
2.1. Istniejące rozwiązania . . . . .	10
2.2. Porównanie projektu z istniejącymi rozwiązaniami . . . . .	11
<b>3. System rozpoznawania emocji z głosu</b>	<b>12</b>
3.1. Ogólny proces rozpoznawania emocji z głosu . . . . .	12
3.2. Dźwięk, podstawowe definicje . . . . .	12
3.3. Dobór cech dźwięku . . . . .	14
3.4. Ekstrakcja cech . . . . .	15
3.5. Normalizacja . . . . .	16
3.6. Klasyfikacja . . . . .	16
<b>4. K najbliższych sąsiadów</b>	<b>17</b>
4.1. Opis algorytmu . . . . .	17
4.2. Implementacja . . . . .	17
<b>5. Ukryte Modele Markowa</b>	<b>19</b>
5.1. Opis modelu . . . . .	19
5.2. Implementacja . . . . .	20

<b>6. Wyniki</b>	<b>22</b>
6.1. Baza danych mowy emocjonalnej . . . . .	22
6.2. Wyniki . . . . .	22
<b>7. Wnioski i podsumowanie</b>	<b>25</b>
<b>Bibliografia</b>	<b>27</b>

# Rozdział 1.

## Wprowadzenie

### 1.1. Geneza projektu

Rozmowa jest najbardziej naturalnym sposobem wymiany informacji. Dzięki niej możemy przekazywać wiedzę, wyrażać uczucia i wpływać na stan emocjonalny odbiorcy. Jednak często ciężko jest ludziom wyrazić słowami myśli i uczucia. Dlatego w celu poprawy jakości oraz kontroli rozmowy, tak ważna jest umiejętność rozpoznawania komunikatów niewerbalnych.

Rozwój technologii umożliwił komunikację online. Coraz częściej ludzie do wymiany informacji używają telefonów lub komputerów. Jest to wygodny oraz szybki sposób prowadzenia konwersacji. Jednak komunikacja internetowa znacznie różni się od tej tradycyjnej. Pomimo że cel jest ten sam, to sposoby jego osiągnięcia bardzo się różnią. Podczas komunikacji tradycyjnej oprócz słów korzystamy z gestów i mimiki oraz widzimy reakcję osoby, z którą rozmawiamy. Dzięki temu możemy przekazać i odczytać więcej informacji. Te dodatkowe metody umożliwiają lepsze rozpoznanie stanu emocjonalnego i intencji mówcy. Niestety, nie zawsze jest to możliwe podczas komunikacji internetowej. Rozpoznawanie emocji w tym przypadku ogranicza się jedynie do interpretacji głosu, jego tonu, energii czy barwy. Złe zinterpretowanie tych sygnałów często prowadzi do konfliktów. System, który umożliwiłby rozpoznawanie stanu emocjonalnego mówcy, ułatwiłby i poprawiłby jakość komunikacji we współczesnym życiu.

Elektronika jest coraz powszechniej wykorzystywana przez ludzi. Roboty pomagają znaleźć drogę, służą jako rozrywka oraz pomoc w codziennych czynnościach. Coraz więcej czasu spędzamy przed ekranem urządzeń elektronicznych. Jednak maszyny nie wiedzą co czujemy. Umiejętność rozpoznawania przez urządzenia emocji na podstawie tylko głosu, znacznie zwiększyłaby jakość komunikacji człowiek-komputer. Maszyny na podstawie danych o stanie emocjonalnym człowieka, mogłyby dostosowywać swoje zachowanie do stanu odbiorcy i tym samym wpływać na jego reakcje. Obecnie coraz powszechniejsze jest wykrywanie emocji z mimiki twarzy. Powstają

programy, które śledzą ruchy mięśni twarzy i na tej podstawie są w stanie określić stan emocjonalny człowieka. Jednak dokładnie przetwarzanie obrazu wymaga dużej złożoności obliczeniowej oraz profesjonalnego sprzętu. Natomiast przetwarzanie dźwięku jest prostsze i szybsze, dlatego nawet prosty sprzęt mógłby spełniać takie funkcje.

Urządzenie do wykrywania emocji z głosu dałoby również możliwość nauki lepszej kontroli nad swoim głosem. Umiejętność ta poprawiłaby jakość rozmów, zwiększyła pewność siebie a także ułatwiłaby kontakt między ludźmi. Często, podczas rozmowy, gdy jeden z jej uczestników podnosi głos i tym samym wyraża złość, reszta reaguje tym samym. Dlatego coraz powszechniejsze stają się szkolenia z kontroli nad swoimi emocjami, podczas których dużą uwagę zwraca się na głos. Taka aplikacja umożliwiłaby trenowanie głosu każdemu.

## 1.2. Cel projektu

Celem pracy jest zaimplementowanie i porównanie działania algorytmu k najbliższych sąsiadów i algorytmu bazującego na ukrytych modelach Markowa oraz zaimplementowanie systemu, który korzystając z nich, umożliwiłby rozpoznawanie emocji na podstawie nagranych fragmentów wypowiedzi. Za cechy odpowiadające emocjom zdecydowano wybrać cechy związane z tonem podstawowym oraz natężeniem dźwięku. Emocje, jakie program powinien przewidywać to: szczęście, smutek, znudzenie i złość.

## 1.3. Zakres pracy

1. Analiza plików dźwiękowych w formacie .wav
2. Wydobycie z fragmentów wypowiedzi i obliczenie cech związanych z tonem podstawowym oraz natężeniem dźwięku
3. Zaimplementowanie algorytmu „k najbliższych sąsiadów” dla problemu rozpoznawania emocji z głosu.
4. Zaimplementowanie algorytmu bazującego na ukrytych modelach Markowa dla problemu rozpoznawania emocji z głosu.
5. Zaimplementowanie aplikacji, która korzystając z tych algorytmów i opierając się na bazie danych mowy emocjonalnej, potrafiłaby rozpoznawać emocje z głosu.
6. Porównanie działania i wyników dwóch powyższych algorytmów w kontekście rozważanego problemu.



Wszystkie wymienione powyżej punkty, sposoby rozwiązania poszczególnych problemów, ogólny proces działania aplikacji oraz przedstawienie wyników zostały opisane i uzasadnione w niniejszej pracy. W rozdziale drugim zaprezentowane zostały już istniejące rozwiązania i stan wiedzy na temat rozważanego problemu oraz porównanie projektu z już istniejącymi rozwiązaniami. W kolejnej części opisany jest ogólny proces działania systemu do rozpoznawania emocji z głosu. Znajdują się tam również odpowiednie definicje, opis operacji oraz uzasadnienie wyboru cech dźwięku użytych do rozpoznawania stanu emocjonalnego. Kolejne dwa rozdziały opisują algorytmy: k najbliższych sąsiadów i ukryte modele Markowa oraz sposób ich implementacji dla problemu rozpoznawania emocji z głosu. Następna część prezentuje wyniki testów obydwóch algorytmów na niemieckiej bazie danych mowy emocjonalnej. Wnioski z testów oraz przykładowe możliwości rozszerzenia projektu znajdują się w ostatnim rozdziale pracy, wraz z jej podsumowaniem.

## Rozdział 2.

# Stan wiedzy w zakresie tematyki pracy

### 2.1. Istniejące rozwiązania

Badania nad wykrywaniem zmian stanu emocjonalnego człowieka na podstawie cech głosu są coraz powszechniejsze. Przez ostatnich parę lat pojawiło się kilka prac na ten temat.

Przykładem jest praca [10] opublikowana w 2016 roku, w której autorzy opisują swoje badania na ten temat. Autorzy, używając konwolucyjnych sieci neuronowych oraz algorytmu piramid, stworzyli aplikację, która z powodzeniem odczytuje emocje na podstawie fragmentów wypowiedzi. Do klasyfikacji emocji wykorzystują różne cechy dźwięku, takie jak MFCC czy cechy prozodyczne. Poprawność programu była zależna od bazy danych, na której przeprowadzili testy. Wynosiła ona od ok. 44% dla jednej z wykorzystanych baz danych do nawet ok. 87% dla innej.

Kolejnym algorytmem, jaki jest często wykorzystywany w tym problemie jest SVM (Support Vector Machine). Autorzy opublikowanej w 2013 roku na konferencji KST („International Conference on Knowledge and Smart Technology”) pracy [9] pod tytułem: „Speech Emotion Recognition using Support Vector Machines” wykorzystują ten algorytm do problemu rozpoznawania emocji z głosu. Używają cech głosu związanych z tonem podstawowym, energią i MFCC. Następnie testują wyniki na trzech różnych bazach danych. Poprawność wyników wynosi od 89,80% dla niemieckiej bazy danych do nawet 98% dla tajskiej bazy danych.

Warto również wspomnieć o projekcie stworzonym przez firmę Affectiva. Firma stworzyła aplikację „Emotion API for Speech”, która za pomocą algorytmów sztucznej inteligencji pozwala rozpoznawać emocję z głosu [4]. Jednak aplikacja nie jest ogólnie dostępna.

## 2.2. Porównanie projektu z istniejącymi rozwiązaniami

Istniejące rozwiązania bazują na dużej ilości cech dźwięku użytych w celu rozpoznawania dużej ilości emocji. Celem tego projektu wykorzystanie podstawowych i szybkich do obliczenia cech głosu, czyli ton podstawowy i natężenie dźwięku i próba predykcji emocji na ich podstawie. Dałoby to również obraz tego, jak charakterystyczne są te cechy dla wybranych emocji.


## Rozdział 3.

# System rozpoznawania emocji z głosu

### 3.1. Ogólny proces rozpoznawania emocji z głosu

Rozpoznawanie emocji z głosu jest procesem złożonym z kilku faz. Pierwszą jest dobór odpowiednich cech głosu, na podstawie których program będzie odróżniać poszczególne emocje. Następnym krokiem jest wydobywanie ich z fragmentów wypowiedzi. Po wydobywaniu odpowiednich cech należy je znormalizować. Umożliwia to ich wzajemne porównywanie w dalszej części analizy. W ostatniej fazie należy uruchomić algorytm klasyfikujący, który na podstawie tych danych zwraca wynik. W dalszej części rozdziału opisana jest każda z tych faz. Rysunki 3.1 i 3.2 przedstawiają ogólny proces działania trenowania i testowania systemu do rozpoznawania emocji z głosu.

Rysunek 3.1: Process trenowania systemu do rozpoznawania emocji z głosu

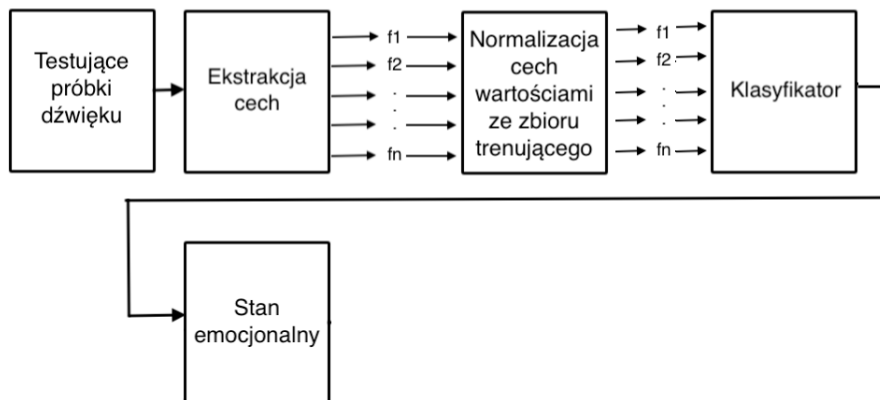


### 3.2. Dźwięk, podstawowe definicje

Formalnie fala dźwiękowa to rozchodzące się w ośrodku zaburzenie, któremu towarzyszą drgania cząsteczek ośrodka i która powoduje wrażenie słuchowe [6]. Fale mają pewne fundamentalne cechy jak:

1. Długość fali – odległość pomiędzy początkiem a końcem jednego pełnego cyklu.

Rysunek 3.2: Process testowania systemu do rozpoznawania emocji z głosu



2. Amplituda – poziom wychylenia z położenia równowagi. Amplituda fali akustycznej mierzona jest na 2 sposoby:

- maksymalne wychylenie – maksymalny pozytywny lub negatywny poziom sygnału,
- średnia kwadratowa (RMS) – która mierzy bardziej znaczący średni poziom sygnału.

3. Częstotliwość – czyli liczba pełnych drgań (cykli), jakie wykona fala w ciągu jednej jednostki czasu (np. sekundy). Jej jednostką jest herc(Hz).

Drganie fałd głosowych podczas wydechu powoduje wibracje, tworząc fale dźwiękowe. Następnie na skutek różnych procesów, takich jak ruchy języka, podniebienia, szczęk nabierają one specyficznych właściwości, tworząc wrażenie słuchowe nazywane głosem. Podstawowe cechy głosu to: barwa głosu, jego wysokość, oraz natężenie.

Barwa głosu zależy od ilości oraz zachowania tonów w dźwięku. To właśnie dzięki niej jesteśmy w stanie odróżniać głosy poszczególnych osób. Właściwość ta jest mocno uzależniona od budowy gardła, krtani, fałd głosowych.

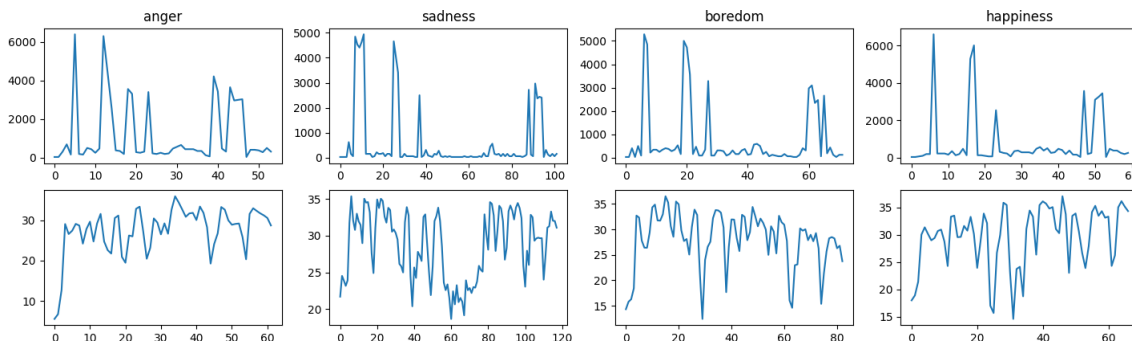
Wysokość głosu zależy od częstotliwości fali, a dokładniej od częstotliwości tonu podstawowego. Ton to fala harmoniczna (sinusoidalna). Niższa częstotliwość tego tonu oznacza większą długość fali, a co za tym idzie niższą wysokość. Natomiast, wraz ze wzrostem częstotliwości długość fali maleje, zmniejszając wysokość głosu. Wysokość podobnie jak częstotliwość podaje się w hercach. Ton głosu, pomimo że będzie miał taką samą wartość Hz, może być głośniejszy lub cichszy w zależności od swojej amplitudy.

Natężenie dźwięku jest miarą energii fali dźwiękowej i zależy od jej amplitudy.

### 3.3. Dobór cech dźwięku

Jak już zostało wspomniane, w projekcie w celu rozpoznawania emocji z głosu, zdecydowano się użyć cech związanych z wysokością głosu oraz natężeniem. Na rysunku 3.3 znajdują się wykresy tych cech dla czterech emocji na których skupia się praca.

Rysunek 3.3: Przykładowy rozkład zmian wartości tonu podstawowego oraz natężenia w czasie



W pierwszym wierszu dla każdej emocji widzimy rozkład tonu podstawowego w czasie, natomiast w drugim wierszu rozkład natężenia. Możemy z niego wywnioskować podstawowe zależności pomiędzy poszczególnymi emocjami. Na przykład: wysoki ton głosu i wysoka energia są charakterystyczne przy okazywaniu złości, natomiast również wysoki ton i troszkę niższa energia są charakterystyczne dla szczęścia. Smutek cechuje się bardzo niskim tonem głosu i dużą dynamiką energii, natomiast znużenie trochę wyższym tonem głosu niż smutek, ale niższym niż dwie pozostałe emocje oraz trochę stabilniejszym poziomem energii.

Na podstawie tych danych, informacji zaczerpniętych z pracy [6] i internetowego kursu [2] zostało wybrane dwanaście cech, które mogłyby reprezentować stany emocjonalne. Są to:

1. różnica między maksymalną a minimalną wartością tonu podstawowego,
2. maksymalna wartość tonu podstawowego,
3. minimalna wartość tonu podstawowego,
4. średnia wartość tonu podstawowego,
5. dynamika tonu podstawowego,
6. procent tonów opadających,
7. procent tonów wzrastających,
8. relatywne standardowe odchylenie wartości tonu podstawowego,

9. relatywne standardowe odchylenie wartości średniej kwadratowej natężenia,
10. gęstość przejść przez zero,
11. średnia kwadratowa natężenia,
12. największa wartość natężenia.

W celu dokładniejszego doboru parametrów dźwięku skorzystano z algorytmu ExtraTreeClassifier z jednej z bibliotek języka Python: sklearn [11]. Algorytm oblicza stopień ważności każdej z cech. Wynik algorytmu przedstawia tabela 3.1.

Tablica 3.1: Tabela reprezentująca stopień ważności wybranych cech głosu

Różnica między maksymalną a minimalną wartością tonu podstawowego	0.080200
Maksymalna wartość tonu podstawowego	0.103055
Minimalna wartość tonu podstawowego	0.098071
Średnia wartość tonu podstawowego	0.112797
Dynamika tonu podstawowego	0.020013
Procent tonów opadających	0.052253
Procent tonów wzrastających	0.047792
Relatywne standardowe odchylenie wartości tonu podstawowego	0.089292
Relatywne standardowe odchylenie wartości średniej kwadratowej natężenia	0.100254
Gęstość przejść przez zero	0.099278
Średnia kwadratowa natężenia	0.102582
Największa wartość natężenia	0.094414

Na podstawie uzyskanych wyników zdecydowano się zrezygnować z cechy nazwanej „dynamika tonu podstawowego”. Ostatecznie do rozpoznawania emocji użyto pozostałych jedenastu cech.

### 3.4. Ekstrakcja cech

Ekstrakcja cech polega na analizie sygnału dźwiękowego i wydobyciu z niego potrzebnych wartości. W projekcie, aby wydobyć odpowiednie cechy z sygnału dźwiękowego, co 0.125 sekundy brana jest próbka dźwięku o długości 0.25 sekundy. Z próbek o tej długości wyliczane są odpowiednie cechy. Sygnał odczytywany z pliku jest sygnałem w domenie czasu. Z takiego sygnału możemy odczytać wszystkie wartości związane z energią, czyli:

- relatywne standardowe odchylenie wartości średniej kwadratowej natężenia,
- gęstość przejść przez zero,
- średnia kwadratowa natężenia,

- największa wartość natężenia.

Aby wydobyć cechy związane z częstotliwością, należy sygnał w domenie czasu przekształcić na sygnał w domenie częstotliwości. Operacją, która na to pozwala, jest transformacja Fouriera. W projekcie wykorzystano algorytm szybkiej transformaty Fouriera dla rzeczywistych danych wejściowych: `rfft`, znajdujący się w bibliotece języka Python: `numpy.fft`. Z sygnału w domenie częstotliwości wydobyto częstotliwość podstawową i na jej podstawie wyliczono pozostałe cechy.

### 3.5. Normalizacja

Obliczone cechy mają różną wartość. Maksymalna wartość cech obliczanych w procentach to sto, podczas gdy maksymalna wartość częstotliwości jest dużo wyższa. Z tego względu, podczas liczenia podobieństwa wektorów cechy z większą rangą będą uważane jako bardziej istotne. Aby temu zapobiec, przeprowadza się normalizację wektorową. W wyniku tej operacji, wartości cech są z przedziału  $\langle 0, 1 \rangle$ . Dzięki temu wpływ wszystkich cech na wynik jest taki sam. Normalizacja przebiega według następującego wzoru:

$$a_i' = \frac{a_i - \min(a_i)}{\max(a_i) - \min(a_i)}$$

### 3.6. Klasyfikacja

Znormalizowany wektor cech podajemy jako argumenty do klasyfikatora. Jeżeli wektor był wektorem trenującym, algorytm trenuje klasyfikator. Natomiast jeżeli wektor był wektorem testującym, to zwraca stan emocjonalny reprezentujący podany wektor cech.



## Rozdział 4.

# K najbliższych sąsiadów

### 4.1. Opis algorytmu

K najbliższych sąsiadów (KNN) jest algorytmem często wykorzystywanym w informatyce do klasyfikacji lub przewidywania wartości zmiennej losowej.

W pracy posłużono się algorytmem KNN opisanym w podręczniku do statystyki stworzonym przez firmę StatSoft [13]. Algorytm w trakcie trenowania nie przeprowadza żadnych obliczeń. Jedynie zapamiętuje zbiór wektorów trenujących  $T$  w postaci  $[X_i, Y_i]$ , gdzie  $X_i$  oznacza  $i$ -tą obserwację, natomiast  $Y_i$  przewidywaną zmienną  $i$ -tej obserwacji.

Podczas testowania podana jest obserwacja  $O$ . Celem algorytmu jest prognoza przewidywanej wartości tej obserwacji. W tym celu algorytm:

1. oblicza odległość pomiędzy  $O$  a każdą z obserwacji ze zbioru trenującego;
2. tworzy zbiór  $O'$ , w którego skład wchodzi  $k$  najbliższych położonych od niego obserwacji ze zbioru trenującego;
3. przeprowadza głosowanie wśród elementów ze zbioru  $O'$  i obserwacji  $O$  przypisuje element, który wystąpił największą ilość razy.

### 4.2. Implementacja

W części trenującej program tworzy moduł KNN i podaje mu zbiór wektorów w postaci [wektor cech, emocja jaką reprezentuje]. Moduł KNN normalizuje wektory ze zbioru, zapamiętuje je oraz parametry użyte do normalizacji.

W części testującej program podaje modułowi KNN zbiór wektorów cech  $V$  wypowiedzi. Algorytm KNN najpierw dla każdego wektora  $w \in V$  normalizuje  $w$  wartościami użytymi do normalizacji zbioru trenującego, a następnie przeprowadza al-

gorytm testowania opisany na początku tego rozdziału. Jako emocję reprezentującą wypowiedź algorytm zwraca emocję, która została najczęściej przypisana wektorom ze zbioru  $V$ . Jeżeli więcej niż jedna emocja wystąpiła najczęściej, zwracana jest losowa z nich.

## Rozdział 5.

# Ukryte Modele Markowa

### 5.1. Opis modelu

Ukryte modele Markowa (HMM) to narzędzie służące do statystycznej analizy sekwencji zdarzeń. Aby zrozumieć ten model, należy zacząć od definicji łańcucha Markowa.

Łańcuch Markowa jest modelem składającym się ze zbioru stanów  $S$  oraz macierzy  $M$ , zawierającej prawdopodobieństwa przejść pomiędzy stanami. Opisuje układ, który w danym momencie czasu może znajdować się tylko w jednym ze swoich stanów, a w następnym przejść do innego lub pozostać w swoim z prawdopodobieństwem zapisanym w macierzy  $M$ . Cechą charakterystyczną dla łańcucha Markowa jest to, że zachowuje on własność Markowa, która mówi, że w czasie  $t + 1$  prawdopodobieństwo bycia w stanie  $j$  zależy jedynie od stanu w jakim układ znajdował się w czasie  $t$ .

Ukryty model Markowa jest modelem zawierającym:

- stany, które tworzą łańcuch Markowa
- zbiór możliwych obserwacji
- macierz prawdopodobieństw przejść pomiędzy stanami  $M$  ( $M_{ij}$  oznacza prawdopodobieństwo przejścia ze stanu  $i$  do stanu  $j$ )
- macierz emisji  $E$  ( $E_{ij}$  oznacza prawdopodobieństwo emisji obserwacji  $j$  w stanie  $i$ )

Ukryte Modele Markowa zakładają, że stany tworzące łańcuch Markowa są ukryte. Widoczna jest tylko obserwacja jaką stan zwróci. Na tej podstawie i mając dane z tablicy emisji oraz przejść, HMM jest w stanie obliczyć prawdopodobną sekwencję stanów, która wyrzuciła dany wektor obserwacji oraz prawdopodobieństwo wygenerowania obserwacji w modelu.

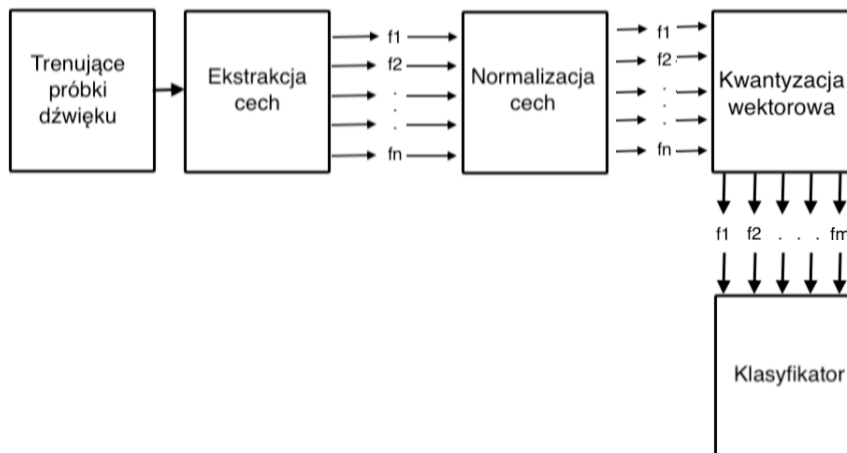
W projekcie wykorzystano liniowy model HMM [1, Chapter 8.1]. Charakteryzuje on się tym, że w czasie  $t$ , ze stanu  $s_i$  możemy przejść do stanu  $s_{i+1}$  lub pozostać w stanie  $s_i$ , z pewnym prawdopodobieństwem. Prawdopodobieństwo przejścia do pozostałych stanów jest zerowe. Do trenowania ukrytych modeli Markowa wykorzystano algorytm Bauma-Welcha, natomiast w celu obliczenia prawdopodobieństwa wygenerowania obserwacji przez model wykorzystano algorytm prefiksowy. Definicje i dokładny opis algorytmów można znaleźć w pracy „Wstęp do ukrytych modeli Markowa i metody Bauma–Welcha” [14].

## 5.2. Implementacja

W pierwszej fazie program tworzy zbiór wszystkich możliwych obserwacji. W tym celu, z każdego pliku w zbiorze trenującym pobiera wektory cech. Kolejnym etapem jest normalizacja stworzonego zbioru wektorów. W celu zmniejszenia liczby obserwacji i uśrednienia ich program używa algorytmu  $k$ -średnich, o nazwie KMeans z biblioteki sklearn [11]. Algorytm tworzy podaną ilość możliwych obserwacji.

W części trenującej program dla każdej emocji i każdego pliku trenującego reprezentującego tę emocję tworzy zbiór sześciu wektorów cech, będących sekwencją 1,5-sekundowej wypowiedzi. Każdy wektor cech reprezentuje 0.25 sekundy wypowiedzi. Następnie wektory zostają znormalizowane i każdy z nich zostaje zamieniony na najbliższą jej obserwację ze zbioru obserwacji. Dzięki temu algorytm jest w stanie ją rozpoznać. Następnie dla każdej emocji tworzy oddzielny model HMM i trenuje go zbiorem sekwencji odpowiadających emocji, jaką reprezentuje model.

Rysunek 5.1: Process trenowania modelu HMM do rozpoznawania emocji z głosu



Podczas testowania z pliku będącego wypowiedzią, algorytm oblicza zbiór obserwacji  $O$ . Każdy z elementów obserwacji reprezentuje zbiór 6 wektorów cech będących sekwencją 1,5-sekundowej wypowiedzi. Kolejnym krokiem jest normalizacja każdej obserwacji, wartościami, którymi był normalizowany zbiór wszystkich możliwych wartości. Każdy ze znormalizowanych wektorów cech zostaje zamieniony na

najbliższy mu wektor ze zbioru obserwacji, tworząc zbiór  $S$ . Dzięki temu model HMM będzie je rozpoznawał. Następnie, program dla każdej obserwacji ze zbioru  $S$  i każdego modelu HMM, wylicza prawdopodobieństwo wygenerowania tej obserwacji w tym modelu. Jako emocję, która odpowiada tej obserwacji wybiera tę, która reprezentuje model HMM, który wyliczył największe prawdopodobieństwo jej wygenerowania. Jako emocję reprezentującą wypowiedź algorytm zwraca emocję, która po przejściu wszystkich obserwacji ze zbioru  $O$  wystąpiła najczęściej. Jeżeli więcej niż jedna emocja wystąpiła najczęściej, zwracana jest losowa z nich.

## Rozdział 6.

# Wyniki

### 6.1. Baza danych mowy emocjonalnej

W celu przetestowania algorytmów użyto niemieckiej bazy mowy emocjonalnej [5]. Wybrano właśnie tę bazę danych, ponieważ jest ona publicznie dostępna oraz w istniejących rozwiązaniach, testy na tej bazie danych charakteryzowały się dużą poprawnością. Ponadto baza zawiera wszystkie cztery emocje, na których skupia się ten projekt.

### 6.2. Wyniki

W algorytmie KNN, najlepszy wynik został wygenerowany przy liczbie stanów równej 17. Wyniki prezentuje tabela 6.1.

Widać z niej, że algorytm k najbliższych sąsiadów wykrył poprawnie 68.45% emocji. Najlepiej radzi sobie z emocjami, które cechują się wyrazistymi różnicami jak złość, którą cechuje wysoki ton i wysoka energia oraz smutek, który cechuje niski ton i niska energia. Natomiast gorzej radzi sobie z emocjami, których właściwości nie są tak wyraziste. Szczęście w 39,13% myli ze złością, która cechuje się podobnymi parametrami, natomiast znudzenie myli w 38,46% ze smutkiem. A więc na podstawie wyników algorytmu można również stwierdzić podobieństwo sposobu wyrażania poszczególnych emocji.

System rozpoznający emocje z głosu bazujący na ukrytych modelach Markowa został przetestowany na stanach od 200, do 700. Najlepsze wyniki pod kątem poprawności i szybkości działania uzyskał dla 500 stanów. Tabela 6.2 prezentuje wyniki algorytmu:

Widać z niej, że algorytm bazujący na Ukrytych Modelach Markowa wykrył poprawnie 62,41% emocji. Podobnie jak KNN bardzo dobrze rozpoznaje emocje takie smutek czy złość. Natomiast gorzej radzi sobie z emocjami takimi jak szczęście

i znudzenie, myląc je odpowiednio ze złością i smutkiem.

Oba wyniki mają podobne cechy. Mylą szczęście ze złością oraz znudzenie ze smutkiem. Jak przyjrzymy się jeszcze raz wykresom z rysunku 3.3, możemy zauważyć podobieństwo wysokości i natężenia głosu w tych emocjach. Jak widzimy na przykładzie szczęścia i złości, szczęście ma niewiele mniejsze parametry co złość. Podobnie z pozostałymi dwoma emocjami. W celu dokładniejszego porównania podobieństwa cech tych emocji obliczono średnią wartość tych cech z wszystkich wypowiedzi ze zbioru trenującego. Tabela 6.3 prezentuje uzyskane wyniki:

Z powyższej tabeli można odczytać, że średnie wartości cech w emocjach, które algorytmy mylą są bardzo podobne. Przez to szczęście często mylone jest ze złością, która cechuje się niewiele większymi parametrami i nachodzi na tę emocję. Podobnie jest w przypadku znudzenia i smutku.

Pomimo podobieństw widać, że algorytmy całkiem dobrze poradziły sobie z zadaniem. Cechy, które w projekcie użyto nie wystarczą do dokładnego rozpoznawania emocji z głosu, ale nadają się do rozpoznawania podstawowych emocji, zmian stanu z pobudzonego na spokojny i wiele innych. Wynik działania algorytmu można poprawić dodając dodatkowe cechy na przykład na cechy związane z: jakością głosu (prędkość mówienia, płynność) lub cechy spektralne MFCC, LFPC.

Tablica 6.1: Tabela przedstawiająca wyniki działania programu rozpoznającego emocje z użyciem algorytmu k najbliższych sąsiadów

emocja	szczęście	złość	smutek	znudzenie
szczęście	39.13%	60.86%	0%	0%
złość	12,5	85%	0%	2,5%
smutek	0%	0%	95,83%	4,16%
znudzenie	0%	7,69%	38,46%	53,85%

Tablica 6.2: Tabela przedstawiająca wyniki działania programu rozpoznającego emocje z użyciem algorytmu bazującego na ukrytych modelach Markowa

emocja	szczęście	złość	smutek	znudzenie
szczęście	39,13%	47,83%	8,70%	4,35%
złość	10%	72,5%	0%	2,5%
smutek	0%	0%	91,87%	8,33%
znudzenie	0%	3,85%	50%	46,15%

Tablica 6.3: Tabela przedstawiająca średnie wartości cech dla każdej z emocji

cecha/emocja	złość	szczęście	smutek	znudzenie
Ranga tonu głosu	1984.25	1869.97	1172.018	1169.39
Maksymalny ton	2180.92	2052.31	1238.78	1274.70
Minimalny ton	196.67	182.34	66.77	105.31
Średnia wartość tonu	879.42	801.53	439.23	487.50
Procent tonów opadających	46.54	45.24	32.95	36.35
Procent tonów wzrastających	44.13	42.20	31.98	35.16
Std odchylenie tonu podstawowego	80.16	80.56	80.09	74.31
Std odchylenie natężenia	40.84	36.51	29.27	29.35
Gęstość przejść przez zero	2.04	1.48	0.76	0.76
Średnia kwadratowa natężenia	29.43	29.69	30.04	31.29
Największa wartość natężenia	15.08	14.22	12.25	12.71



## Rozdział 7.

# Wnioski i podsumowanie

Algorytm k najbliższych sąsiadów poradził sobie lepiej z tym problemem. Jednakże różnica jest niewielka. Poprawność wyników, jakie zwróciły oba algorytmy, wynosi ponad 60%. Jednak algorytm KNN jest prostszy do zaimplementowania oraz czas działania tego algorytmu jest szybszy. Także biorąc pod uwagę również te cechy, spisuje się o wiele lepiej.

Warto jednak zwrócić uwagę, że istnieje dużo różnych możliwości implementacji ukrytych modeli Markowa, oraz sposobów trenowania go. W projekcie zdecydowano się użyć modelu liniowego oraz do trenowania, algorytmu Bauma-Welcha. Inny model może zwrócić zupełnie inne wyniki.

Projekt inżynierski opracowany w tej pracy ma za zadanie rozpoznawać cztery podstawowej emocje: szczęście, złość, smutek oraz znużenie. Do swojego działania wykorzystuje jeden z dwóch algorytmów: k najbliższych sąsiadów lub algorytmu bazującego na ukrytych modelach Markowa, w zależności od wyboru użytkownika. Ponadto do projektu dodano dodatkową opcję, która pozwala śledzić przebieg częstotliwości i natężenia w czasie w plikach .wav. Praca została wykonana w pełnym zakresie i zgodnie z założonym celem. Wyniki pracy zostały zaprezentowane i opisane w pracy. Do projektu jest załączona dokumentacja w postaci html i pdf, która zawiera opis funkcji programu.

Projekt można rozwinąć. Możliwe usprawnienia:

- dodanie kolejnych cech dźwięku w celu przetestowania wpływu tych właściwości na poprawne rozpoznawanie emocji,
- dodanie większej liczby emocji,
- implementacja innych algorytmów w celu przetestowania ich działania w tym problemie.

# Spis rysunków

3.1	Process trenowania systemu do rozpoznawania emocji z głosu . . . .	12
3.2	Process testowania systemu do rozpoznawania emocji z głosu . . . .	13
3.3	Przykładowy rozkład zmian wartości tonu podstawowego oraz natężenia w czasie . . . . .	14
5.1	Process trenowania modelu HMM do rozpoznawania emocji z głosu .	20

# Spis tablic

3.1	Tabela reprezentująca stopień ważności wybranych cech głosu . . . .	15
6.1	Tabela przedstawiająca wyniki działania programu rozpoznającego emocje z użyciem algorytmu k najbliższych sąsiadów . . . . .	24
6.2	Tabela przedstawiająca wyniki działania programu rozpoznającego emocje z użyciem algorytmu bazującego na ukrytych modelach Markowa	24
6.3	Tabela przedstawiająca średnie wartości cech dla każdej z emocji . .	24

# Bibliografia

- [1] Fink Gernot A. *Markov Models for Pattern Recognition*. Springer London Ltd, 2014.
- [2] *AC Circuits*. URL: <https://www.electronics-tutorials.ws/accircuits/ac-waveform.html>.
- [3] Maria M. Suarez-Alvarez i Duc-Truong Pham i Mikhail Y. Prostov i Yuriy I. Prostov. *Statistical approach to normalization of feature vectors and clustering of mixed datasets*. Paź. 2012. DOI: <https://doi.org/10.1098/rspa.2011.0704>.
- [4] *Emotion API for Speech*. URL: <https://www.affectiva.com/product/emotion-api-speech/>.
- [5] Prof. Dr. W. Sendlmeier i Felix Burkhardt i Miriam Kienast i Astrid Paeschke i Benjamin Weiss. *Berlin Database of Emotional Speech*. URL: <http://emodb.bilderbar.info/start.html>.
- [6] Mikołaj Kirpluk. *Podstawy akustyki*. Rozd. Fala dźwiękowa, Parametry akustyczne-definicje. URL: <http://ntlmkirpluk.republika.pl/M.Kirpluk%5C%20-%5C%20Podstawy%5C%20akustyki%5C%20-%5C%202014-09.pdf>.
- [7] Robert J. Elliot i Lakhdar Aggoun i John B. Moore. *Hidden Markov Model Estimation and Control*. Springer Science+Business Media, LLC, 1995.
- [8] Stuart J. Russell i Peter Norvig. *Artificial Intelligence A Modern Approach Third Edition*. Pearson, 2009. Rozd. Probabilistic reasoning over time.
- [9] Thapane Seehapoch i Sartra Wongthanavas. *Speech Emotion Recognition using Support Vector Machines*. Maj 2013. DOI: <http://ieeexplore.ieee.org/document/6512793/>.
- [10] Shiqing Zhang i Shilliang Zhang i Tiejun Huang i Wen Gao. *Speech Emotion Recognition Using Deep Convolutional Neural Network and Discriminant Temporal Pyramid Matching*. T. PP. 99. Paź. 2017. DOI: <http://ieeexplore.ieee.org/document/8085174/>.
- [11] *Sklearn documentation*. URL: <http://scikit-learn.org/stable/>.

- [12] Steven W. Smith. *The Scientist and Engineer's Guide to Digital Signal Processing*. California Technical Publishing, 1997. Rozd. Applications of the DFT, Fourier Transform Properties, The Fast Fourier Transform, Continuous Signal Processing. ISBN: 0-9660176-3-3. URL: <http://www.dspguide.com/pdfbook.htm>.
- [13] Inc. (2013) StatSoft. *Electronic Statistics Textbook*. Rozd. k-Nearest Neighbors. URL: <http://www.statsoft.com/textbook/>.
- [14] Piotr Wiktor Zwiernik. *Wstęp do ukrytych modeli Markowa i metody Bauma–Welcha*. Sty. 2005. URL: <https://www.mimuw.edu.pl/p%CC%83zwiernik/docs/hmm.pdf>.